

## 2. Computación científica, representación numérica y análisis del error

Representación de números. Punto flotante IEEE-754

Métodos Numéricos

Edwin Fernando Muñoz

# ¿Por qué estudiar la representación de números?

## Idea fundamental

Un computador únicamente puede almacenar un conjunto finito de números, mientras que el conjunto de los números reales es infinito.

Por esta razón, antes de estudiar cualquier método numérico es necesario comprender:

- ▶ cómo representa un computador los números;
- ▶ qué números pueden almacenarse;
- ▶ cuáles son las limitaciones de dicha representación.

## Objetivo de esta sesión

Estudiar la representación de números en punto flotante, fundamento de la aritmética utilizada por los computadores modernos.

Fuente: Turner, Arildsen y Kavanagh (2018), Sección 2.1.

# Representación posicional de un número

Sea  $\beta \geq 2$  una base entera.

Todo número positivo puede escribirse como

$$x = a_n\beta^n + a_{n-1}\beta^{n-1} + \cdots + a_1\beta + a_0 + a_{-1}\beta^{-1} + \cdots + a_{-m}\beta^{-m},$$

donde

$$a_k \in \{0, 1, \dots, \beta - 1\}.$$

De forma compacta,

$$x = \sum_{k=-m}^n a_k \beta^k.$$

Fuente: Turner, Arildsen y Kavanagh (2018), Sección 2.2.

# Representación de punto flotante

La representación anterior puede escribirse mediante la forma de **punto flotante**

$$x = f \beta^E,$$

donde

- ▶  $f$  representa la **mantisa** (o significando);
- ▶  $\beta$  corresponde a la base del sistema;
- ▶  $E$  es el exponente.

La representación en punto flotante permite expresar números de muy distinta magnitud utilizando una estructura común.

Fuente: Turner, Arildsen y Kavanagh (2018), ecuación (2.1).

# Representación normalizada

En un sistema de punto flotante normalizado, la mantisa debe satisfacer

$$1 \leq f < \beta.$$

La mantisa puede escribirse como

$$f = b_0 + b_1\beta^{-1} + b_2\beta^{-2} + \cdots + b_N\beta^{-N},$$

o, de forma equivalente,

$$f = \sum_{k=0}^N b_k\beta^{-k}.$$

## Observación

La normalización garantiza una representación única del número y constituye la base de los sistemas de punto flotante utilizados en los computadores.

Fuente: Turner, Arildsen y Kavanagh (2018), ecuaciones (2.2) y (2.3).

# Representación binaria de punto flotante

En los computadores modernos, la base utilizada es

$$\beta = 2.$$

Por tanto, un número de punto flotante se representa como

$$x = f 2^E,$$

donde la mantisa satisface

$$1 \leq f < 2.$$

Como únicamente existen dos dígitos binarios,

$$0 \quad \text{y} \quad 1,$$

la mantisa puede escribirse como

$$f = 1 + b_1 2^{-1} + b_2 2^{-2} + \cdots + b_N 2^{-N}.$$

Fuente: Turner, Arildsen y Kavanagh (2018), ecuación (2.4).

# El bit implícito

En una representación binaria normalizada,

$$1 \leq f < 2,$$

el primer dígito binario de la mantisa siempre es

1.

Por esta razón, dicho bit no necesita almacenarse explícitamente y recibe el nombre de

**bit implícito.**

## Observación

Como el primer bit siempre es igual a 1, no es necesario almacenarlo explícitamente. Esto permite utilizar ese espacio para representar un bit adicional de la parte fraccionaria de la mantisa.

Fuente: Turner, Arildsen y Kavanagh (2018), sección 2.2.

# Cifras significativas

Las **cifras significativas** corresponden a los dígitos que contienen información sobre la precisión de un número.

Reglas básicas:

- ▶ Todo dígito distinto de cero es significativo.
- ▶ Los ceros entre dígitos distintos de cero son significativos.
- ▶ Los ceros al inicio de un número no son significativos.
- ▶ Los ceros finales después del punto decimal son significativos.

Ejemplos:

|         |   |                          |
|---------|---|--------------------------|
| 101,05  | → | 5 cifras significativas, |
| 0,00452 | → | 3 cifras significativas, |
| 12,300  | → | 5 cifras significativas. |

Fuente: Turner, Arildsen y Kavanagh (2018), sección 2.2.

# Ejemplo: representación de $\pi$

Considere la aproximación

$$\pi = 3,141593,$$

la cual posee siete cifras significativas.

En notación científica normalizada,

$$\pi = 3,141593 \times 10^0.$$

Si únicamente se conservan cuatro cifras significativas,

$$\pi \approx 3,142 \times 10^0.$$

Mientras que con seis cifras significativas,

$$\pi \approx 3,14159 \times 10^0.$$

Fuente: Turner, Arildsen y Kavanagh (2018), Ejemplo 1.

# Estándar IEEE-754

El estándar IEEE-754 define la representación utilizada por la mayoría de los computadores para almacenar números de punto flotante.

| Componente                            | Precisión simple | Precisión doble |
|---------------------------------------|------------------|-----------------|
| Signo                                 | 1 bit            | 1 bit           |
| Exponente                             | 8 bits           | 11 bits         |
| Mantisa (incluyendo el bit implícito) | 24 bits          | 53 bits         |

En consecuencia,

32 bits      y      64 bits

corresponden a los formatos de precisión simple y doble, respectivamente.

Fuente: Turner, Arildsen y Kavanagh (2018), Tabla 2.1.

# Representación de números en Python

Python utiliza, por defecto, el formato de precisión doble definido por el estándar IEEE-754 para representar números de punto flotante.

Esto implica que:

- ▶ la mantisa dispone de 53 bits significativos;
- ▶ la representación corresponde a 64 bits;
- ▶ la precisión es aproximadamente de 16 cifras decimales significativas.

En las próximas sesiones utilizaremos Python para observar cómo estas características influyen en los cálculos numéricos.

Fuente: Turner, Arildsen y Kavanagh (2018), sección 2.2.1.

# Bibliografía

-  Turner, P. R. (2018). *Applied Scientific Computing with Python*. Springer.
-  Nocedal, J., & Wright, S. J. (2006). *Numerical Optimization*. Springer.
-  Kroese, D. P., Taimre, T., & Botev, Z. I. (2011). *Handbook of Monte Carlo Methods*. Wiley.
-  Goodfellow, I., Bengio, Y., & Courville, A. (2016). *Deep Learning*. MIT Press.