

2. Computación científica, representación numérica y análisis del error

Overflow, Underflow, cancelación numérica. Laboratorio Python.

Métodos Numéricos

Edwin Fernando Muñoz

Contenido

Overflow y Underflow

- Overflow y Underflow

- Cancelación numérica

Ejercicio propuesto 1

Determine el número de términos de la serie exponencial que se necesitan para obtener $e^{0,1}$ con un error menor que 10^{-8} . Evalúe la suma de estos términos y verifique que se alcanza la precisión deseada.

Solución (Parte 1)

La serie de Maclaurin de la función exponencial es

$$e^x = \sum_{n=0}^{\infty} \frac{x^n}{n!}.$$

Para $x = 0.1$,

$$e^{0,1} = 1 + 0.1 + \frac{0.1^2}{2!} + \frac{0.1^3}{3!} + \frac{0.1^4}{4!} + \dots$$

Como $x = 0.1$, los términos de la serie disminuyen rápidamente de magnitud. **Por ello, el primer término omitido proporciona una buena estimación del error de truncamiento.** Calculamos:

$$\frac{0.1^5}{5!} = 8,33 \times 10^{-8},$$

$$\frac{0.1^6}{6!} = 1,39 \times 10^{-9} < 10^{-8}.$$

Por tanto, el primer término que satisface la tolerancia es $\frac{0,1^6}{6!}$. En consecuencia, deben conservarse los términos desde $n = 0$ hasta $n = 5$.

Solución (Parte 2)

La aproximación utilizando los primeros seis términos es

$$\begin{aligned}e^{0,1} &\approx 1 + 0,1 + \frac{0,1^2}{2!} + \frac{0,1^3}{3!} + \frac{0,1^4}{4!} + \frac{0,1^5}{5!} \\ &= 1,1051709167.\end{aligned}$$

El valor de referencia es

$$e^{0,1} = 1,1051709181.$$

Por tanto, el error absoluto es

$$\begin{aligned}E_a &= |1,1051709181 - 1,1051709167| \\ &= 1,41 \times 10^{-9}.\end{aligned}$$

Como

$$1,41 \times 10^{-9} < 10^{-8},$$

se concluye que

La aproximación cumple la precisión solicitada.

Ejercicio propuesto 2

Escriba las representaciones normalizadas en punto flotante binario de

$$\frac{1}{3}, \frac{1}{5}, \frac{1}{6}, \frac{1}{7}, \frac{1}{9} \text{ y } \frac{1}{10}.$$

Utilice un número suficiente de bits en la mantisa para observar los patrones periódicos de cada representación.

Solución: representación binaria de $\frac{1}{3}$

Para convertir $\frac{1}{3} = 0,3333 \dots_{10}$ a binario, multiplicamos repetidamente la parte fraccionaria por 2. La parte entera obtenida en cada paso corresponde al siguiente bit.

Paso	Multiplicación	Bit obtenido
1	$\frac{1}{3} \times 2 = \frac{2}{3}$	0
2	$\frac{2}{3} \times 2 = 1 + \frac{1}{3}$	1
3	$\frac{1}{3} \times 2 = \frac{2}{3}$	0
4	$\frac{2}{3} \times 2 = 1 + \frac{1}{3}$	1

Como vuelve a aparecer la fracción $\frac{1}{3}$, el procedimiento se repite indefinidamente. Por tanto,

$$\frac{1}{3} = 0,0101010101 \dots_2 = 0.\overline{01}_2.$$

Para normalizar, desplazamos el punto binario dos posiciones hacia la derecha:

$$0,0101010101 \dots_2 = 1,0101010101 \dots_2 \times 2^{-2}. \text{ Rta: } \frac{1}{3} = 1.\overline{01}_2 \times 2^{-2}.$$

Solución: representación binaria de $\frac{1}{5}$

Para convertir $\frac{1}{5} = 0,2_{10}$ a binario, multiplicamos repetidamente la parte fraccionaria por 2. La parte entera obtenida en cada paso corresponde al siguiente bit.

Paso	Multiplicación	Bit obtenido
1	$\frac{1}{5} \times 2 = \frac{2}{5}$	0
2	$\frac{2}{5} \times 2 = \frac{4}{5}$	0
3	$\frac{4}{5} \times 2 = 1 + \frac{3}{5}$	1
4	$\frac{3}{5} \times 2 = 1 + \frac{1}{5}$	1

Como vuelve a aparecer la fracción $\frac{1}{5}$, el procedimiento se repite indefinidamente. Por tanto,

$$\frac{1}{5} = 0,001100110011\dots_2 = 0.\overline{0011}_2.$$

Para normalizar, desplazamos el punto binario tres posiciones hacia la derecha:

$$0,001100110011\dots_2 = 1,100110011001\dots_2 \times 2^{-3}.$$

Resumen de las representaciones normalizadas

Número	Representación binaria	Representación normalizada
$\frac{1}{3}$	$0.\overline{01}_2$	$1.\overline{01}_2 \times 2^{-2}$
$\frac{1}{5}$	$0.\overline{0011}_2$	$1,100110011001\dots_2 \times 2^{-3}$
$\frac{1}{6}$	$0,001010101010\dots_2$	$1,010101010101\dots_2 \times 2^{-3}$
$\frac{1}{7}$	$0.\overline{001}_2$	$1.\overline{001}_2 \times 2^{-3}$
$\frac{1}{9}$	$0.\overline{000111}_2$	$1,110001110001\dots_2 \times 2^{-4}$
$\frac{1}{10}$	$0,0001100110011\dots_2$	$1,100110011001\dots_2 \times 2^{-4}$

Ejercicio propuesto 3

¿Cuántos términos del desarrollo en serie

$$\cosh x = 1 + \frac{x^2}{2!} + \frac{x^4}{4!} + \cdots = \sum_{k=0}^{\infty} \frac{x^{2k}}{(2k)!}$$

se necesitan para estimar

$$\cosh\left(\frac{1}{2}\right)$$

con un error de truncamiento menor que

$$10^{-8}?$$

Verifique que su respuesta alcanza la precisión deseada.

Solución: serie de cosh(x)

La función coseno hiperbólico se representa mediante la serie de Maclaurin

$$\cosh x = \sum_{k=0}^{\infty} \frac{x^{2k}}{(2k)!} = 1 + \frac{x^2}{2!} + \frac{x^4}{4!} + \frac{x^6}{6!} + \dots$$

Sustituyendo $x = \frac{1}{2}$, se obtiene

$$\cosh\left(\frac{1}{2}\right) = 1 + \frac{\left(\frac{1}{2}\right)^2}{2!} + \frac{\left(\frac{1}{2}\right)^4}{4!} + \frac{\left(\frac{1}{2}\right)^6}{6!} + \dots$$

Como $\left(\frac{1}{2}\right)^{2k} = \frac{1}{2^{2k}}$,
la serie puede escribirse como

$$\cosh\left(\frac{1}{2}\right) = 1 + \frac{1}{2^2 2!} + \frac{1}{2^4 4!} + \frac{1}{2^6 6!} + \frac{1}{2^8 8!} + \dots$$

Definimos el término general

$$a_k = \frac{1}{2^{2k}(2k)!}.$$

Solución: prueba con cuatro términos

Supongamos que se conservan los términos correspondientes a

$$k = 0, 1, 2, 3.$$

La aproximación contiene entonces cuatro términos:

$$1 + \frac{1}{2^2 2!} + \frac{1}{2^4 4!} + \frac{1}{2^6 6!}.$$

El primer término omitido corresponde a $k = 4$:

$$a_4 = \frac{1}{2^8 8!}.$$

se obtiene

$$a_4 = \frac{1}{256(40320)} = \frac{1}{10\,321\,920} \approx 9,6881 \times 10^{-8}.$$

Como todos los términos omitidos son positivos,

$$R_3 > a_4.$$

Por consiguiente, $R_3 > 9,6881 \times 10^{-8} > 10^{-8}$. Cuatro términos no son suficientes.

Solución: prueba con cinco términos

Ahora se conservan los términos correspondientes a

$$k = 0, 1, 2, 3, 4.$$

El primer término omitido corresponde a $k = 5$:

$$a_5 = \frac{1}{2^{10} 10!}.$$

Se obtiene

$$a_5 = \frac{1}{1024(3\,628\,800)} \approx 2,6911 \times 10^{-10}.$$

se concluye que

Se necesitan cinco términos.

Solución: aproximación y verificación

Utilizando los primeros cinco términos,

$$\begin{aligned}\cosh\left(\frac{1}{2}\right) &\approx 1 + \frac{(1/2)^2}{2!} + \frac{(1/2)^4}{4!} + \frac{(1/2)^6}{6!} + \frac{(1/2)^8}{8!} \\ &= 1 + \frac{1}{8} + \frac{1}{384} + \frac{1}{46080} + \frac{1}{10\,321\,920} \\ &= 1,127625964936756.\end{aligned}$$

El valor de referencia es $\cosh\left(\frac{1}{2}\right) = 1,127625965206381$.

Por tanto, el error absoluto es

$$\begin{aligned}E_a &= |1,127625965206381 - 1,127625964936756| \\ &\approx 2,69625 \times 10^{-10}.\end{aligned}$$

Como $2,69625 \times 10^{-10} < 10^{-8}$,

Los cinco términos alcanzan la precisión solicitada.

Overflow y Underflow

Los computadores únicamente pueden representar un conjunto finito de números. Como consecuencia, algunos resultados pueden quedar fuera del rango permitido por la máquina.

Overflow

Ocurre cuando el resultado de una operación es demasiado grande para ser representado en el sistema de punto flotante.

Underflow

Ocurre cuando el valor absoluto de un resultado es tan pequeño que no puede ser representado por la máquina.

Observación

Estos fenómenos son consecuencia de que el computador dispone de un número finito de exponentes para representar los números reales.

Fuente: Turner (2018), Sección 2.2.

Ejemplo de Overflow

Considere la multiplicación

$$(3,456 \times 10^3)(3,456 \times 10^7) = 1,19439360000 \times 10^{11}.$$

En la máquina decimal hipotética presentada por Turner, este resultado es demasiado grande para ser representado.

Overflow

De manera análoga, si el valor absoluto de un resultado es demasiado pequeño para ser representado, se produce un

Underflow.

Fuente: Turner (2018), Sección 2.2.

Consecuencias

Las operaciones que producen overflow o underflow deben tratarse con cuidado, ya que pueden generar resultados sin significado o provocar el fallo de un programa.

En muchos sistemas,

- ▶ el **underflow** se reemplaza por cero;
- ▶ el **overflow** se representa mediante

$$+\infty \quad \text{o} \quad -\infty.$$

Idea clave

Cuando un resultado parece inesperado, una de las primeras verificaciones debe ser si ocurrió un fenómeno de overflow o underflow.

Fuente: Turner (2018), Sección 2.2.

Cancelación numérica

La **cancelación numérica** ocurre cuando se restan dos números muy cercanos entre sí. En estas situaciones, las cifras significativas comunes se cancelan y el resultado puede quedar afectado por los errores de redondeo.

Considere el siguiente ejemplo:

$$a = 1,23456789, \quad b = 1,23456780.$$

Entonces,

$$a - b = 0,00000009.$$

Aunque ambos números se conocen con alta precisión, una pequeña perturbación en cualquiera de ellos puede producir un cambio importante en el resultado de la resta.

Idea clave

La cancelación numérica puede amplificar los errores de redondeo y reducir considerablemente la precisión de un cálculo.

Nota: Concepto complementario de análisis numérico.

Bibliografía

-  Turner, P. R. (2018). *Applied Scientific Computing with Python*. Springer.
-  Nocedal, J., & Wright, S. J. (2006). *Numerical Optimization*. Springer.
-  Kroese, D. P., Taimre, T., & Botev, Z. I. (2011). *Handbook of Monte Carlo Methods*. Wiley.
-  Goodfellow, I., Bengio, Y., & Courville, A. (2016). *Deep Learning*. MIT Press.