

Semana 6, sesión 12

3. Álgebra lineal numérica

Mínimos cuadrados y factorización QR

Métodos Numéricos

Edwin Fernando Muñoz

Resumen de la sesión anterior

- Un sistema lineal cuadrado se escribe como

$$\boxed{Ax = b}, \quad A \in \mathbb{R}^{n \times n}.$$

- En la eliminación de Gauss se eliminan, de forma sucesiva, las incógnitas por debajo del pivote.
- El objetivo de la eliminación hacia adelante es transformar el sistema original en un sistema triangular superior.
- Una vez obtenida la forma triangular, la solución se calcula mediante **sustitución hacia atrás**.

$$\boxed{Ax = b \longrightarrow Ux = c \longrightarrow x}$$

1.2 Eliminación de Gauss

La operación particular puede describirse mediante el siguiente ciclo:

Para $j = 2 : n$

$$m := \frac{a_{j1}}{a_{11}}; \quad a_{j1} := 0$$

Para $k = 2 : n$

$$a'_{jk} := a_{jk} - ma_{1k}$$

Fin

$$b'_j := b_j - mb_1$$

Fin

En el algoritmo general, la notación prima será eliminada y los elementos de la matriz y del vector del lado derecho serán reemplazados por sus nuevos valores.

Algoritmo: eliminación hacia adelante de Gauss

Entrada

$$A \in \mathbb{R}^{n \times n}, \quad \mathbf{b} \in \mathbb{R}^n.$$

Proceso

Para $i = 1 : n - 1$

Para $j = i + 1 : n$

$$m := \frac{a_{ji}}{a_{ii}}; \quad a_{ji} := 0$$

Para $k = i + 1 : n$

$$a_{jk} := a_{jk} - m a_{ik}$$

Fin

$$b_j := b_j - m b_i$$

Fin

Fin

Salida: matriz triangular superior y lado derecho modificado.

Sistemas lineales no cuadrados

En general,

$$\boxed{Ax = b}, \quad A \in \mathbb{R}^{m \times n},$$

donde

m = número de ecuaciones, n = número de incógnitas.

- ▶ $m = n$: sistema **cuadrado**.
- ▶ $m > n$: sistema **sobredeterminado**.
- ▶ $m < n$: sistema **subdeterminado**.

En esta sesión nos concentraremos en el caso

$$\boxed{m > n}.$$

Sistema sobredeterminado

Un sistema es **sobredeterminado** cuando

$$m > n,$$

es decir, hay más ecuaciones que incógnitas. Por ejemplo,

$$x_1 + x_2 = 2,$$

$$x_1 + 2x_2 = 3,$$

$$x_1 + 3x_2 = 5.$$

En forma matricial,

$$\begin{bmatrix} 1 & 1 \\ 1 & 2 \\ 1 & 3 \end{bmatrix} \begin{bmatrix} x_1 \\ x_2 \end{bmatrix} = \begin{bmatrix} 2 \\ 3 \\ 5 \end{bmatrix}, \quad A \in \mathbb{R}^{3 \times 2}.$$

¿Existe una solución exacta?

De las dos primeras ecuaciones,

$$x_1 + x_2 = 2,$$

$$x_1 + 2x_2 = 3,$$

se obtiene

$$x_2 = 1, \quad x_1 = 1.$$

Sin embargo, en la tercera ecuación,

$$x_1 + 3x_2 = 1 + 3(1) = 4 \neq 5.$$

Por tanto, no existe un vector x que satisfaga simultáneamente las tres ecuaciones.

Un sistema sobredeterminado puede ser incompatible.

De solución exacta a solución aproximada

Cuando no existe solución exacta,

$$Ax \neq b.$$

Se define el **vector residuo**

$$r = b - Ax.$$

Si la solución fuera exacta,

$$r = 0.$$

En un sistema incompatible buscamos entonces una solución aproximada que haga pequeño el residuo:

buscar x para que $\|r\|_2$ sea lo menor posible.

Ejemplo: cálculo del residuo

Considere el sistema sobredeterminado

$$x_1 + x_2 = 2,$$

$$x_1 + 2x_2 = 3,$$

$$x_1 + 3x_2 = 5.$$

En forma matricial:

$$\begin{bmatrix} 1 & 1 \\ 1 & 2 \\ 1 & 3 \end{bmatrix} \begin{bmatrix} x_1 \\ x_2 \end{bmatrix} = \begin{bmatrix} 2 \\ 3 \\ 5 \end{bmatrix}.$$

Las dos primeras ecuaciones producen

$$x_1 = 1, \quad x_2 = 1.$$

Pero al verificar la tercera:

$$1 + 3(1) = 4 \neq 5.$$

Por tanto,

$$Ax \neq b.$$

El sistema no tiene solución exacta.

Ejemplo: vector residuo

Tomemos la aproximación encontrada:

$$x = \begin{bmatrix} 1 \\ 1 \end{bmatrix}.$$

Calculamos

$$Ax = \begin{bmatrix} 1 & 1 \\ 1 & 2 \\ 1 & 3 \end{bmatrix} \begin{bmatrix} 1 \\ 1 \end{bmatrix} = \begin{bmatrix} 2 \\ 3 \\ 4 \end{bmatrix}.$$

El vector residuo es

$$r = b - Ax.$$

Entonces,

$$r = \begin{bmatrix} 2 \\ 3 \\ 5 \end{bmatrix} - \begin{bmatrix} 2 \\ 3 \\ 4 \end{bmatrix} = \begin{bmatrix} 0 \\ 0 \\ 1 \end{bmatrix}.$$

Problema de mínimos cuadrados

La norma euclidiana del residuo es

$$\|r\|_2 = \sqrt{r_1^2 + r_2^2 + \cdots + r_m^2}.$$

Como

$$r = b - Ax,$$

se plantea

$$\min_x \|b - Ax\|_2.$$

Equivalentemente,

$$\min_x \|b - Ax\|_2^2 = \min_x \sum_{i=1}^m r_i^2.$$

Este es el **problema de mínimos cuadrados**.

Ejemplo: aproximación por mínimos cuadrados

Para el sistema

$$A = \begin{bmatrix} 1 & 1 \\ 1 & 2 \\ 1 & 3 \end{bmatrix}, \quad b = \begin{bmatrix} 2 \\ 3 \\ 5 \end{bmatrix},$$

buscamos el vector $x = \begin{bmatrix} x_1 \\ x_2 \end{bmatrix}$ que minimice $\|b - Ax\|_2$. Tomemos inicialmente

$$x = \begin{bmatrix} 1 \\ 1 \end{bmatrix}.$$

Entonces,

$$Ax = \begin{bmatrix} 1 & 1 \\ 1 & 2 \\ 1 & 3 \end{bmatrix} \begin{bmatrix} 1 \\ 1 \end{bmatrix} = \begin{bmatrix} 2 \\ 3 \\ 4 \end{bmatrix}.$$

El residuo es

$$r = b - Ax = \begin{bmatrix} 0 \\ 0 \\ 1 \end{bmatrix}.$$

Por tanto, $\|r\|_2 = 1$.

Ejemplo: buscar una mejor aproximación

La solución

$$x = \begin{bmatrix} 1 \\ 1 \end{bmatrix}$$

produce un error

$$\|r\|_2 = 1.$$

El problema de mínimos cuadrados consiste en encontrar otro vector

$$x = \begin{bmatrix} x_1 \\ x_2 \end{bmatrix}$$

tal que

$$\|b - Ax\|_2$$

sea menor. Es decir, buscamos la aproximación que deje la menor distancia entre Ax y b . La solución óptima será aquella que minimice la suma de los errores al cuadrado:

$$\min_x \sum_{i=1}^m r_i^2.$$

Ecuaciones normales y dificultad numérica

Una forma de resolver mínimos cuadrados conduce a

$$A^T A x = A^T b.$$

Si $A \in \mathbb{R}^{m \times n}$, entonces

$$A^T A \in \mathbb{R}^{n \times n},$$

por lo que se obtiene un sistema cuadrado. Sin embargo, si A tiene rango columna completo,

$$\kappa_2(A^T A) = \kappa_2(A)^2.$$

Así, formar $A^T A$ puede amplificar problemas de condicionamiento.

Buscamos una alternativa numéricamente más estable: QR.

Factorización QR reducida

Para

$$A \in \mathbb{R}^{m \times n}, \quad m \geq n,$$

y suponiendo columnas linealmente independientes, se busca

$$A = QR,$$

con

$$Q \in \mathbb{R}^{m \times n}, \quad R \in \mathbb{R}^{n \times n}.$$

Las matrices cumplen

$$Q^T Q = I, \quad R \text{ triangular superior}.$$

Las columnas de Q forman una base ortonormal del espacio columna de A .

¿Por qué QR ayuda en mínimos cuadrados?

El problema es

$$\min_x \|b - Ax\|_2.$$

En la solución de mínimos cuadrados, el residuo

$$r = b - Ax$$

es ortogonal al espacio columna de A . Como $A = QR$ y Q genera el mismo espacio columna,

$$\boxed{Q^T r = 0}.$$

Entonces,

$$Q^T (b - QRx) = 0.$$

Usando $Q^T Q = I$,

$$\boxed{Rx = Q^T b}.$$

Interpretación numérica

La factorización QR transforma

$$\min_x \|b - Ax\|_2$$

en

$$Rx = Q^T b.$$

Como

$$R = \begin{bmatrix} r_{11} & r_{12} & \cdots & r_{1n} \\ 0 & r_{22} & \cdots & r_{2n} \\ \vdots & \ddots & \ddots & \vdots \\ 0 & \cdots & 0 & r_{nn} \end{bmatrix},$$

la solución se obtiene mediante **sustitución hacia atrás**.

$$A \longrightarrow Q, R \longrightarrow Q^T b \longrightarrow x$$

Ejemplo: sistema sobredeterminado

Considere

$$\begin{aligned}x_1 + x_2 &= 2, \\x_1 + 2x_2 &= 3, \\x_1 + 3x_2 &= 5, \\x_1 + 4x_2 &= 6.\end{aligned}$$

En forma matricial,

$$A = \begin{bmatrix} 1 & 1 \\ 1 & 2 \\ 1 & 3 \\ 1 & 4 \end{bmatrix}, \quad b = \begin{bmatrix} 2 \\ 3 \\ 5 \\ 6 \end{bmatrix}.$$

Como

$$A \in \mathbb{R}^{4 \times 2}, \quad m = 4 > 2 = n,$$

el sistema es sobredeterminado.

Ejemplo: factorización QR

Para

$$A = \begin{bmatrix} 1 & 1 \\ 1 & 2 \\ 1 & 3 \\ 1 & 4 \end{bmatrix},$$

una factorización QR reducida es

$$Q = \begin{bmatrix} \frac{1}{2} & -\frac{3}{2\sqrt{5}} \\ \frac{1}{2} & -\frac{1}{2\sqrt{5}} \\ \frac{1}{2} & \frac{1}{2\sqrt{5}} \\ \frac{1}{2} & \frac{3}{2\sqrt{5}} \end{bmatrix}, \quad R = \begin{bmatrix} 2 & 5 \\ 0 & \sqrt{5} \end{bmatrix}.$$

Se verifica que

$$\boxed{A = QR}, \quad \boxed{Q^T Q = I}.$$

Ejemplo: sistema triangular

Primero,

$$Q^T b = \begin{bmatrix} 8 \\ \frac{7}{\sqrt{5}} \end{bmatrix}.$$

Por tanto,

$$\begin{bmatrix} 2 & 5 \\ 0 & \sqrt{5} \end{bmatrix} \begin{bmatrix} x_1 \\ x_2 \end{bmatrix} = \begin{bmatrix} 8 \\ \frac{7}{\sqrt{5}} \end{bmatrix}.$$

Por sustitución hacia atrás,

$$x_2 = \frac{7}{5} = 1,4, \quad x_1 = 0,5.$$

Así,

$$\boxed{x = \begin{bmatrix} 0,5 \\ 1,4 \end{bmatrix}}.$$

Ejemplo: residuo e interpretación

Con

$$x = \begin{bmatrix} 0,5 \\ 1,4 \end{bmatrix},$$

se obtiene

$$Ax = \begin{bmatrix} 1,9 \\ 3,3 \\ 4,7 \\ 6,1 \end{bmatrix}, \quad b = \begin{bmatrix} 2 \\ 3 \\ 5 \\ 6 \end{bmatrix}.$$

El residuo es

$$r = b - Ax = \begin{bmatrix} 0,1 \\ -0,3 \\ 0,3 \\ -0,1 \end{bmatrix}.$$

No se obtuvo una solución exacta, pero sí el vector que minimiza

$$\|b - Ax\|_2.$$

De Gauss a mínimos cuadrados mediante QR

$$Ax = b$$

$$A \in \mathbb{R}^{n \times n}$$



Eliminación de Gauss



Sistema triangular



Sustitución hacia atrás

$$A \in \mathbb{R}^{m \times n}, m > n$$



Mínimos cuadrados



$$A = QR$$



$$Rx = Q^T b$$



Sustitución hacia atrás

¿Cómo se construyen Q y R ?

La factorización

$$A = QR$$

requiere construir una base ortonormal a partir de las columnas de A .

Aspecto	Gram-Schmidt clásico	Gram-Schmidt modificado
Idea	Calcula las proyecciones respecto de las columnas originales.	Actualiza cada vector después de cada proyección.
Redondeo	Puede perder ortogonalidad cuando las columnas son casi dependientes.	Conserva mejor la ortogonalidad en aritmética finita.
Uso	Muy útil para comprender la construcción.	Preferible para una implementación numérica básica.

Ejemplo común

Considere

$$A = \begin{bmatrix} 1 & 1 \\ 1 & 0 \\ 0 & 1 \end{bmatrix} = \begin{bmatrix} | & | \\ \mathbf{a}_1 & \mathbf{a}_2 \\ | & | \end{bmatrix},$$

con

$$\mathbf{a}_1 = \begin{bmatrix} 1 \\ 1 \\ 0 \end{bmatrix}, \quad \mathbf{a}_2 = \begin{bmatrix} 1 \\ 0 \\ 1 \end{bmatrix}.$$

Buscamos

$$\boxed{A = QR}, \quad Q \in \mathbb{R}^{3 \times 2}, \quad R \in \mathbb{R}^{2 \times 2}.$$

Gram-Schmidt clásico: primera columna

Para la primera columna,

$$r_{11} = \|a_1\|_2 = \sqrt{1^2 + 1^2 + 0^2} = \sqrt{2}.$$

Luego,

$$q_1 = \frac{a_1}{r_{11}} = \frac{1}{\sqrt{2}} \begin{bmatrix} 1 \\ 1 \\ 0 \end{bmatrix}.$$

Para la segunda columna se calcula la proyección

$$r_{12} = q_1^T a_2 = \frac{1}{\sqrt{2}}.$$

Entonces,

$$u_2 = a_2 - r_{12}q_1.$$

Gram-Schmidt clásico: segunda columna

Se obtiene

$$u_2 = \begin{bmatrix} 1 \\ 0 \\ 1 \end{bmatrix} - \begin{bmatrix} 1/2 \\ 1/2 \\ 0 \end{bmatrix} = \begin{bmatrix} 1/2 \\ -1/2 \\ 1 \end{bmatrix}.$$

Luego,

$$r_{22} = \|u_2\|_2 = \frac{\sqrt{6}}{2},$$

y

$$q_2 = \frac{u_2}{r_{22}} = \frac{1}{\sqrt{6}} \begin{bmatrix} 1 \\ -1 \\ 2 \end{bmatrix}.$$

Gram-Schmidt clásico: resultado

Las columnas ortonormales forman

$$Q = \begin{bmatrix} \frac{1}{\sqrt{2}} & \frac{1}{\sqrt{6}} \\ \frac{1}{\sqrt{2}} & -\frac{1}{\sqrt{6}} \\ 0 & \frac{2}{\sqrt{6}} \end{bmatrix},$$

y los coeficientes calculados forman

$$R = \begin{bmatrix} \sqrt{2} & \frac{1}{\sqrt{2}} \\ 0 & \frac{\sqrt{6}}{2} \end{bmatrix}.$$

Por tanto,

$$\boxed{A = QR}.$$

Resolución mediante QR

Una vez obtenida la factorización

$$A = QR,$$

podemos resolver el problema de mínimos cuadrados. Partimos de

$$Ax \approx b.$$

Sustituyendo,

$$QRx \approx b.$$

Multiplicando por Q^T :

$$Q^T QRx = Q^T b.$$

Como

$$Q^T Q = I,$$

se obtiene el sistema triangular

$$\boxed{Rx = Q^T b}.$$

Ejemplo: resolver el sistema mediante QR

Consideremos

$$A = \begin{bmatrix} 1 & 1 \\ 1 & 0 \\ 0 & 1 \end{bmatrix}, \quad b = \begin{bmatrix} 2 \\ 1 \\ 1 \end{bmatrix}.$$

De la factorización anterior:

$$R = \begin{bmatrix} \sqrt{2} & \frac{1}{\sqrt{2}} \\ 0 & \frac{\sqrt{6}}{2} \end{bmatrix}.$$

Además,

$$Q^T b = \begin{bmatrix} \frac{3}{\sqrt{2}} \\ \frac{1}{\sqrt{6}} \end{bmatrix}.$$

Por tanto, debemos resolver:

$$\begin{bmatrix} \sqrt{2} & \frac{1}{\sqrt{2}} \\ 0 & \frac{\sqrt{6}}{2} \end{bmatrix} \begin{bmatrix} x_1 \\ x_2 \end{bmatrix} = \begin{bmatrix} \frac{3}{\sqrt{2}} \\ \frac{1}{\sqrt{6}} \end{bmatrix}.$$

Ejemplo: sustitución hacia atrás

De la segunda ecuación:

$$\frac{\sqrt{6}}{2}x_2 = \frac{1}{\sqrt{6}},$$

entonces, $x_2 = \frac{1}{3}$.

Luego,

$$\sqrt{2}x_1 + \frac{1}{\sqrt{2}}\frac{1}{3} = \frac{3}{\sqrt{2}}.$$

Multiplicando por $\sqrt{2}$:

$$2x_1 + \frac{1}{3} = 3.$$

Por tanto,

$$x_1 = \frac{4}{3}.$$

Finalmente,

$$x = \begin{bmatrix} \frac{4}{3} \\ \frac{1}{3} \end{bmatrix}$$

es la solución obtenida mediante QR.

Ejemplo: sistema sobredeterminado incompatible

Considere el sistema

$$Ax = b,$$

donde

$$A = \begin{bmatrix} 1 & 1 \\ 1 & 0 \\ 0 & 1 \end{bmatrix}, \quad b = \begin{bmatrix} 2 \\ 1 \\ 2 \end{bmatrix}.$$

El sistema representa:

$$\begin{cases} x_1 + x_2 = 2, \\ x_1 = 1, \\ x_2 = 2. \end{cases}$$

De las dos últimas ecuaciones:

$$x_1 + x_2 = 1 + 2 = 3.$$

Pero la primera ecuación exige:

$$x_1 + x_2 = 2.$$

Por tanto,

Las ecuaciones son incompatibles.

¿Existe una solución exacta?

Para que exista una solución exacta debe cumplirse:

$$Ax = b.$$

Es decir,

$$\begin{bmatrix} 1 & 1 \\ 1 & 0 \\ 0 & 1 \end{bmatrix} \begin{bmatrix} x_1 \\ x_2 \end{bmatrix} = \begin{bmatrix} 2 \\ 1 \\ 2 \end{bmatrix}.$$

Pero no existe ningún vector

$$x = \begin{bmatrix} x_1 \\ x_2 \end{bmatrix}$$

que pueda satisfacer simultáneamente las tres ecuaciones. Por tanto,

$$Ax \neq b$$

para cualquier elección de x .

El sistema no tiene solución exacta.

De solución exacta a solución aproximada

Cuando no existe solución exacta,

$$Ax \neq b.$$

Se define el vector residuo:

$$r = b - Ax$$

Si la solución fuera exacta:

$$r = 0.$$

Como esto no es posible para un sistema incompatible, buscamos una solución aproximada que produzca el menor error:

buscar x para que $\|r\|_2$ sea mínimo

Ejemplo: solución mediante mínimos cuadrados

Consideremos nuevamente

$$A = \begin{bmatrix} 1 & 1 \\ 1 & 0 \\ 0 & 1 \end{bmatrix}, \quad b = \begin{bmatrix} 2 \\ 1 \\ 2 \end{bmatrix}.$$

Como el sistema es incompatible,

$$Ax \neq b,$$

buscamos la solución que minimiza

$$\|b - Ax\|_2.$$

Mediante las ecuaciones normales:

$$A^T Ax = A^T b$$

Ejemplo: resolución del sistema equivalente

Calculamos:

$$A^T A = \begin{bmatrix} 2 & 1 \\ 1 & 2 \end{bmatrix},$$

y

$$A^T \mathbf{b} = \begin{bmatrix} 3 \\ 4 \end{bmatrix}.$$

Por tanto:

$$\begin{bmatrix} 2 & 1 \\ 1 & 2 \end{bmatrix} \begin{bmatrix} x_1 \\ x_2 \end{bmatrix} = \begin{bmatrix} 3 \\ 4 \end{bmatrix}.$$

Resolviendo:

$$2x_1 + x_2 = 3,$$

$$x_1 + 2x_2 = 4.$$

Se obtiene:

$$\mathbf{x}_{LS} = \begin{bmatrix} \frac{2}{3} \\ \frac{3}{5} \\ \frac{5}{3} \end{bmatrix}$$

Esta no es una solución exacta del sistema original, sino la mejor aproximación en el sentido de mínimos cuadrados.

¿Por qué obtenemos una única solución?

Inicialmente consideramos un sistema sobredeterminado:

$$Ax = b,$$

donde

$$A \in \mathbb{R}^{m \times n}, \quad m > n.$$

Es decir, existen más ecuaciones que incógnitas.

Para estos sistemas pueden ocurrir dos situaciones:

Situación	Resultado
Sistema compatible	Puede tener solución única o infinitas soluciones
Sistema incompatible	No existe solución exacta

Cuando

$$Ax \neq b,$$

el sistema es incompatible y no existe ningún vector x que satisfaga todas las ecuaciones simultáneamente.

Interpretación numérica

En métodos numéricos no buscamos resolver exactamente

$$Ax = b.$$

En cambio, buscamos el vector que minimiza el error:

$$\min_x \|b - Ax\|_2$$

Es decir, buscamos la solución más cercana posible.

La factorización QR transforma el problema en:

$$Rx = Q^T b.$$

Como R es triangular superior y no singular,

existe una única solución de mínimos cuadrados

x_{LS}

que es la mejor aproximación al sistema original.

Gram-Schmidt modificado: idea

Se inicia con una copia de las columnas:

$$v_1 = a_1, \quad v_2 = a_2.$$

Para la primera columna,

$$r_{11} = \|v_1\|_2 = \sqrt{2}, \quad q_1 = \frac{v_1}{r_{11}}.$$

Luego,

$$r_{12} = q_1^T v_2 = \frac{1}{\sqrt{2}},$$

y la diferencia esencial es la **actualización inmediata**

$$v_2 \leftarrow v_2 - r_{12}q_1.$$

Gram-Schmidt modificado: actualización

La actualización produce

$$v_2 \leftarrow \begin{bmatrix} 1 \\ 0 \\ 1 \end{bmatrix} - \begin{bmatrix} 1/2 \\ 1/2 \\ 0 \end{bmatrix} = \begin{bmatrix} 1/2 \\ -1/2 \\ 1 \end{bmatrix}.$$

Ahora se trabaja directamente con este vector actualizado:

$$r_{22} = \|v_2\|_2 = \frac{\sqrt{6}}{2},$$

$$q_2 = \frac{v_2}{r_{22}} = \frac{1}{\sqrt{6}} \begin{bmatrix} 1 \\ -1 \\ 2 \end{bmatrix}.$$

Clásico y modificado: ¿qué cambia?

En este ejemplo ambos métodos producen las mismas matrices Q y R . La diferencia está en el **proceso numérico**.

Clásico	Modificado
Las proyecciones se calculan respecto de la columna que se está ortogonalizando.	Cada proyección modifica inmediatamente el vector restante.
La pérdida de ortogonalidad puede ser mayor por redondeo.	La actualización sucesiva reduce esa pérdida en muchos problemas.

MGS: proyectar → actualizar → continuar

Proceso general de Gram-Schmidt modificado

Sea

$$A = \begin{bmatrix} | & | & \cdots & | \\ \mathbf{a}_1 & \mathbf{a}_2 & \cdots & \mathbf{a}_n \\ | & | & \cdots & | \end{bmatrix} \in \mathbb{R}^{m \times n}, \quad m \geq n.$$

Se inicia con

$$\mathbf{v}_j = \mathbf{a}_j, \quad j = 1, \dots, n.$$

Para cada i ,

$$r_{ii} = \|\mathbf{v}_i\|_2, \quad \mathbf{q}_i = \frac{\mathbf{v}_i}{r_{ii}}.$$

Para $j = i + 1, \dots, n$,

$$r_{ij} = \mathbf{q}_i^T \mathbf{v}_j, \quad \boxed{\mathbf{v}_j \leftarrow \mathbf{v}_j - r_{ij} \mathbf{q}_i}.$$

Algoritmo: Gram-Schmidt modificado

Entrada: $A \in \mathbb{R}^{m \times n}$, $m \geq n$, con columnas linealmente independientes.

$$v_j := a_j, \quad j = 1, \dots, n.$$

Para $i = 1 : n$

$$r_{ii} := \|v_i\|_2$$

$$q_i := \frac{v_i}{r_{ii}}$$

Para $j = i + 1 : n$

$$r_{ij} := q_i^T v_j$$

$$v_j := v_j - r_{ij} q_i$$

Fin

Fin

Salida:

$$\boxed{A = QR}, \quad Q^T Q = I, \quad R \text{ triangular superior.}$$

Implementación en Python

```
import numpy as np

A = np.array([
    [1., 1.],
    [1., 2.],
    [1., 3.],
    [1., 4.]
])

b = np.array([2., 3., 5., 6.])

Q, R = np.linalg.qr(A, mode='reduced')
c = Q.T @ b
x = np.linalg.solve(R, c)

r = b - A @ x

print("x =", x)
print("residuo =", r)
print("||r||_2 =", np.linalg.norm(r))
```

Síntesis de la sesión

1. Un sistema sobredeterminado tiene más ecuaciones que incógnitas:

$$m > n.$$

2. Si es incompatible, se busca la solución de mínimos cuadrados:

$$\min_x \|b - Ax\|_2.$$

3. Con QR,

$$A = QR, \quad Q^T Q = I,$$

el problema se reduce a

$$\boxed{Rx = Q^T b}.$$

4. Para construir Q y R , Gram-Schmidt modificado es preferible al clásico en una implementación numérica básica.

Bibliografía



Burden, R. L., & Faires, J. D. *Numerical Analysis*. Cengage Learning.



Golub, G. H., & Van Loan, C. F. *Matrix Computations*. Johns Hopkins University Press.



Higham, N. J. *Accuracy and Stability of Numerical Algorithms*. SIAM.



Trefethen, L. N., & Bau, D. *Numerical Linear Algebra*. SIAM.